

RELATÓRIO TÉCNICO DE ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS

Modelos de Aprendizado de Máquina para Predição e Apoio à Decisão em Qualidade
do Ar Urbano

Disciplina:	DCT1401 - Inteligência Artificial (Período 2026.2)
Docente:	Prof. Me. Thommas K. S. Flores
Discente:	Wallison Valdemiro Silvino Dias
Matrícula:	20250023771
Dataset Oficial:	Greek Urban Air Quality & Health Impact Dataset (2020–2024)
Repositório GitHub:	https://github.com/wallisonvdsdias/air-quality-data

1. Introdução e Contextualização do Problema

No papel de Cientista de Dados atuando em consultoria analítica, o objetivo deste projeto é conduzir uma análise exploratória completa, higienização e engenharia de atributos sobre o conjunto de dados **Greek Urban Air Quality and Health Impact Dataset (2020–2024)**. O propósito final é estruturar um pipeline metodológico robusto que oriente a construção e treinamento de modelos de Aprendizado de Máquina supervisionado sob dois paradigmas distintos: **Regressão** e **Classificação**.

A poluição atmosférica é um dos maiores vetores de morbimortalidade evitável no mundo moderno, associando-se diretamente a patologias respiratórias e cardiovasculares. O monitoramento contínuo em centros urbanos gregos apresenta alta complexidade em decorrência de dinâmicas climáticas locais, alta densidade veicular em metrópoles como Atenas e Tessalônica, além de fenômenos estocásticos graves característicos do Mediterrâneo, tais como tempestades de poeira saariana (*Saharan Dust Events*) e incêndios florestais estivais (*Wildfire Smoke Events*).

O dataset bruto compreende **453.096 medições cronológicas** estruturadas em **32 variáveis** abrangendo dimensões geográficas (12 cidades e 31 estações de monitoramento), meteorológicas (temperatura, umidade, vento, pressão, chuva e radiação UV), concentrações de poluentes químicos e particulados ($PM_{2.5}$, PM_{10} , NO_2 , O_3 , SO_2 , CO, Benzeno), métricas globais de qualidade do ar (AQI), densidade de tráfego, sazonalidade de aquecimento e impactos sanitários estimados.

Característica	Descrição / Valor no Dataset
Volume Total de Amostras	453.096 linhas (registros tri-horários contínuos de 2020 a 2024)
Total de Atributos	32 colunas (27 numéricas e 5 categóricas / temporais)
Cobertura Espacial	12 cidades gregas (Atenas, Tessalônica, Patras, Volos, Heraklion, Larissa, etc.)
Cobertura Temporal	01/01/2020 a 31/12/2024 (resolução temporal de 3 horas)
Integridade Inicial	100% de preenchimento (0 registros nulos ou ausentes em todas as colunas)

2. Análise Exploratória de Dados (EDA)

A condução da EDA permitiu decodificar os padrões de distribuição, dispersão, anomalias e interdependências entre os atributos ambientais e antropogênicos.

2.1 Estatísticas Descritivas e Comportamento Distribucional

A tabela a seguir sumariza os principais momentos estatísticos das variáveis operacionais e poluentes chaves:

Variável	Média	Desvio Padrão	Mínimo	Q1 (25%)	Mediana	Q3 (75%)	Máximo
AQI	93,42	48,58	12,10	56,40	85,20	121,70	729,10
PM2.5 ($\mu\text{g}/\text{m}^3$)	21,57	12,38	1,00	12,15	19,48	28,82	166,11
PM10 ($\mu\text{g}/\text{m}^3$)	39,84	22,84	1,00	22,45	35,98	53,29	336,10
NO2 ($\mu\text{g}/\text{m}^3$)	36,72	21,15	2,00	20,61	33,19	49,52	182,81
CO (mg/m^3)	1,18	0,69	0,10	0,65	1,06	1,58	5,59
Traffic Index	58,21	29,40	6,50	35,10	55,40	78,50	194,30
Temp ($^{\circ}\text{C}$)	18,43	7,92	-3,20	12,30	18,10	24,60	44,70
Wind (m/s)	3,12	1,48	0,00	2,02	2,95	4,05	8,98

2.2 Identificação de Valores Ausentes

A auditoria de completude revelou que **não existem valores ausentes em qualquer coluna** (0,0% de nulos em 453.096 linhas). O gráfico a seguir documenta visualmente a verificação conforme diretrizes da atividade:




Figura 1: Diagnóstico de integridade e completude de dados ausentes.

2.3 Detecção e Discussão sobre a Origem dos Outliers

O método do Intervalo Interquartil ($1,5 \times \text{IQR}$) identificou concentrações expressivas de valores atípicos em variáveis como $\text{PM}_{2.5}$ (2,61%), PM_{10} (2,75%), AQI (2,65%), NO_2 (4,19%) e Densidade de Tráfego (5,14%).

Origem Física e Ambiental: Na ciência atmosférica, valores extremos em particulados finos e gases tóxicos raramente são ruídos mecânicos de sensores; correspondem a eventos exógenos reais de alta magnitude. Na Grécia, episódios severos de *Saharan Dust* transportam poeira mineral de deserto sobre Creta e o Peloponeso, elevando abruptamente o PM_{10} . Concomitantemente, durante o verão seco mediterrâneo, queimadas florestais (*Wildfires*) dispararam as concentrações de $\text{PM}_{2.5}$ para patamares superiores a $150 \mu\text{g}/\text{m}^3$, levando o AQI a ultrapassar 700 (categoria 'Hazardous').




Figura 2: Boxplots horizontais ilustrando a dispersão e presença de caudas longas (outliers).

2.4 Análise de Correlação e Diagnóstico de Multicolinearidade

O cálculo da matriz de correlação de Pearson revelou relações fundamentais entre poluentes, meteorologia e saúde pública:




Figura 3: Matriz de correlação linear de Pearson para as 27 variáveis numéricas.

Pares de Alta Multicolinearidade Identificados ($|r| \geq 0,80$):

- **AQI e Poluentes Críticos:** O AQI possui correlação quase perfeita com $PM_{2.5}$ ($r = 0,9922$) e muito alta com PM_{10} ($r = 0,9439$). Esse fato decorre da própria metodologia de cálculo do índice de qualidade do ar internacional, onde o subíndice do material particulado fino é o preponderante na maioria dos dias.
- **Colinearidade Estrita em Riscos Sanitários:** As variáveis Health_Risk_Children, Health_Risk_Adults e Health_Risk_Elderly apresentam $r = 1,0000$ entre si. Trata-se de reescalonamentos determinísticos lineares. Manter mais de uma geraria colinearidade estrita.
- **Emissões Veiculares:** Correlações elevadas entre Traffic_Density_Index, NO_2 ($r = 0,8558$), CO ($r = 0,8491$) e Benzeno ($r = 0,8710$).
- **Implicações na Modelagem:** Em modelos lineares (OLS, Regressão Logística), essa colinearidade desestabiliza os pesos, aumentando os erros padrão dos coeficientes. O pré-processamento deve adotar regularização (L1 / L2) ou exclusão de redundâncias determinísticas.

2.5 Visualizações de Relações Bivariadas e Distribuição

A análise gráfica bivariada comprova o impacto direto de eventos críticos e densidade de tráfego na degradação da qualidade do ar:




Figura 4: Densidade de Tráfego vs. Concentração de NO₂.




Figura 5: PM_{2.5} vs. AQI colorido por Queimadas.

3. Limpeza e Pré-processamento dos Dados

A preparação adequada dos dados é um pré-requisito mandatório para garantir generalização estatística e evitar vazamento de dados (*data leakage*). As seguintes etapas foram aplicadas e documentadas no pipeline do projeto:

3.1 Tratamento de Valores Ausentes

Como constatado na EDA, o dataset apresenta preenchimento total (0 registros nulos). Não houve necessidade de descarte de instâncias ou imputação artificial nos dados originais. Contudo, em `src/preprocessing.py` foi implementada uma camada defensiva para processamento de novas requisições em tempo de produção, suportando estratégias de preenchimento pela mediana para atributos numéricos de cauda longa e moda para variáveis nominais.

3.2 Racional no Tratamento de Outliers

Decisão Técnica: Preservação Fundamentada e Winsorização Estratificada:

1. *Para Modelos Baseados em Árvores (Random Forest, XGBoost):* Os outliers foram **mantidos na sua integridade**. Descartar valores de $PM_{2.5} > 100 \mu g/m^3$ eliminaria os cenários de incêndios florestais e tempestades do Saara, exatamente onde as decisões de saúde pública são mais críticas. Como árvores de decisão particionam o espaço com hiperplanos ortogonais invariantes a monotonia de escalas, a presença de caudas longas não prejudica seu aprendizado.
2. *Para Modelos Lineares e Baseados em Distância (KNN, SVM, OLS):* Foi aplicada técnica de **Winsorização (Capping)** nos percentis 1% e 99%, restringindo pontos de alavancagem excessiva que distorceriam hiperplanos de regressão linear.

3.3 Codificação de Variáveis Categóricas

- **One-Hot Encoding (OHE):** Aplicado à variável `city` (12 municípios gregos). Como as cidades não possuem relação de ordem natural (nominal pura), a codificação one-hot com remoção da primeira categoria (`drop_first=True`) foi adotada para evitar a armadilha da variável dummy.
- **Ordinal / Label Encoding:** Aplicado à variável alvo de classificação `Outdoor_Activity_Recommendation`, mapeando seus 4 níveis de severidade sanitária ordenada: All activities safe (0), Sensitive groups limit outdoor activity (1), Reduce prolonged outdoor activity (2) e Avoid outdoor activity (3).

3.4 Normalização e Padronização

Variáveis numéricas contínuas com magnitudes heterogêneas (ex: `population` na casa de milhões versus `Wind_Speed_ms` entre 0 e 9) receberam padronização Z-Score através do **StandardScaler** ($z = (x - \mu) / \sigma$), centralizando a média em 0 e variância em 1. Essa etapa é indispensável para convergência via Gradiente Descendente e cálculo preciso de distâncias euclidianas.

3.5 Datasets Processados Exportados

O pipeline gerou e gravou os 3 arquivos processados em `data/processed/`:

1. `dataset_clean.csv`: Base higienizada com features temporais (hora, mês, dia da semana, fim de semana).
2. `dataset_regression.csv`: Atributos meteorológicos, antropogênicos e geográficos padronizados com target contínuo AQI.
3. `dataset_classification.csv`: Poluentes químicos, fatores climáticos e target discreto `target_class` (0 a 3).

4. Percepções para o Problema de Regressão

Identificação da Variável Alvo (Target): Foi selecionado o **AQI (Air Quality Index)**.

Justificativa Aprofundada da Escolha:

- **Amplitude e Continuidade:** Apresenta escala contínua com média 93,42, desvio padrão 48,58 e amplitude de 12,10 a 729,10, sem truncamento artificial.
- **Relevância no Domínio e Aplicação Prática:** O AQI é o indicador oficial de referência internacional para agências ambientais. Modelar e prever o AQI a partir de fatores meteorológicos (vento, chuva, umidade, temperatura) e dados urbanos (tráfego, setor industrial) resolve um desafio de enorme valor prático: **inferir a qualidade do ar sem exigir a instalação de analisadores químicos dispendiosos em cada ponto da cidade.**

4.1 Relação entre Features e o Target AQI

Na modelagem preditiva sem vazamento de dados (excluindo os poluentes que formam a fórmula exata do índice), as variáveis que demonstraram maior poder preditivo foram:

1. **Traffic_Density_Index** ($r = 0,7634$): Principal motor de emissões contínuas no ciclo diário.
2. **Wildfire_Smoke_Event** e **Saharan_Dust_Event**: Variáveis binárias responsáveis pelos desvios severos na cauda superior do AQI.
3. **industrial_index** ($r = 0,3752$) e **population** ($r = 0,4295$): Definem o nível basal de contaminação crônica.
4. **Wind_Speed_ms** e **Temperature_C**: Controlam a dispersão atmosférica e efeito de camada de inversão térmica.




Figura 6: Importância relativa das features preditoras do AQI obtidas via Random Forest Baseline.

4.2 Desafios e Recomendações de Modelagem para Regressão

Desafios: A relação entre clima e qualidade do ar é altamente não-linear e multivariada (ex.: vento forte em dia sem chuva dispersa poluentes, mas em dias de poeira do Saara pode transportar mais material particulado). Além disso, a presença de picos raros de queimadas induz assimetria positiva severa.

Algoritmos Recomendados:

- **XGBoost / LightGBM:** Primeira escolha por excelência. Modelos baseados em gradient boosting com árvores capturam interações de alta ordem, resistem à colinearidade entre variáveis de tráfego e lidam com assimetria.
- **Regressão Ridge / ElasticNet:** Baseline linear regularizado indispensável para benchmarking e interpretação dos coeficientes analíticos.
- **Redes Neurais Multicamadas (MLP):** Alternativa promissora sobre o dataset padronizado para mapear funções não-lineares complexas contínuas.

5. Percepções para o Problema de Classificação

Identificação da Variável Alvo (Target): Foi selecionada a variável **Outdoor_Activity_Recommendation**.

Justificativa Aprofundada da Escolha:

- **Apoio à Decisão e Relevância Clínica:** Traduz medições laboratoriais complexas em recomendações práticas para a população geral e profissionais de saúde (indicação de suspensão de práticas esportivas ao ar livre e confinamento de vulneráveis).
- **Balanceamento Superior de Classes:** A variável alternativa **AQI_Category** contém a classe 'Hazardous' com apenas 0,83% dos dados, provocando colapso de aprendizado em classes raras. Já **Outdoor_Activity_Recommendation** distribui suas 4 classes de maneira equilibrada e sustentável:




Figura 7: Distribuição percentual das 4 classes de recomendação de atividade física ao ar livre.

5.1 Relação entre Features e Classes (Poder Preditivo e Testes de Hipótese)

Para avaliar o poder discriminante dos atributos em relação às classes, executamos testes formais de hipóteses estatísticas:

- **ANOVA One-Way (Features Contínuas):** O teste F apontou diferenciação estatística altamente significativa ($p < 0,0001$) entre os grupos de recomendação, com os maiores valores de F observados em $PM_{2.5}$ ($F > 150.000$) e PM_{10} ($F > 90.000$), seguidos por NO_2 e CO .
- **Teste Qui-Quadrado (χ^2):** Confirmou dependência estatística significativa entre os eventos climáticos (queimadas e poeira do Saara) e as categorias de maior restrição de atividades ($p < 0,0001$).




Figura 8: Boxplots estratificados por categoria evidenciando nítida separabilidade distributiva.

5.2 Desafios e Recomendações de Modelagem para Classificação

Desafios: A variável alvo possui ordenamento intrínseco ($0 < 1 < 2 < 3$). Algoritmos de classificação multiclasse padrão tratam as classes como nominais puras, não penalizando diferentemente um erro entre 'Safe' e 'Avoid' versus 'Safe' e 'Sensitive Limit'.

Algoritmos Recomendados:

- **Random Forest Classifier & LightGBM:** Obteve F_1 -Score $> 0,95$ no baseline inicial, demonstrando separabilidade quase linear no espaço dos particulados.
- **Regressão Logística Multinomial / Ordinal:** Permite gerar estimativas probabilísticas calibradas para emissão de alertas precoces aos órgãos públicos.
- **Métricas de Avaliação Críticas:** Deve-se priorizar o F_1 -Score Macro e a Matriz de Confusão Ponderada por Custo, garantindo sensibilidade elevada nas classes de maior perigo.

6. Considerações Finais

A realização desta atividade proporcionou uma vivência profunda em todas as fases prévias à modelagem em Ciência de Dados e Inteligência Artificial. Dentre os aprendizados e reflexões metodológicas consolidados, destacam-se:

1. **Domínio do Problema Guia o Tratamento de Dados:** Compreender que os outliers em poluição urbana na Grécia derivam de queimadas e poeira desértica evitou o erro crasso de descartá-los estatisticamente, preservando as instâncias de maior valor epidemiológico.
2. **Prevenção de Vazamento de Dados (Data Leakage):** A identificação de multicolinearidade extrema ($r > 0,99$) entre $PM_{2.5}$ e AQI, bem como entre os índices de saúde, demonstrou a importância de formular problemas de predição realistas, utilizando preditores meteorológicos e urbanos para prever o índice ambiental.
3. **Engenharia de Software em Ciência de Dados:** A organização modular do código em pacotes reutilizáveis (src/) e notebooks reproduzíveis assegura manutenibilidade profissional, facilidade de colaboração e auditabilidade acadêmica.

7. Referência ao Repositório de Código-Fonte

Todo o código-fonte, dados processados, notebooks interativos e rotinas auxiliares foram versionados com Git utilizando o padrão *Conventional Commits* e disponibilizados publicamente no repositório GitHub:

Link do Repositório: <https://github.com/wallisonvsdias/air-quality-data>

Etapa	Comando / Instrução de Terminal
1. Clonagem	git clone https://github.com/wallisonvsdias/air-quality-data.git
2. Dados LFS	git lfs pull
3. Pacotes	pip install -r requirements.txt
4. Execução	Execução sequencial dos 4 notebooks em notebooks/

Estrutura de Diretórios e Arquivos do Projeto:

```
air-quality-data/  
|-- README.md                # Documentacao completa, instrucoes e resultados  
|-- requirements.txt          # Dependencias Python do projeto  
|-- .gitattributes            # Rastreamento de arquivos CSV grandes via Git LFS  
|-- .gitignore                # Filtros para caches, ambientes virtuais e checkpoints  
|-- data/  
|   |-- raw/  
|   |   \-- greek_urban_air_quality_2020_2024.csv # Dataset original bruto  
|   \-- processed/  
|       |-- dataset_clean.csv                # Dataset limpo com features temporais  
|       |-- dataset_regression.csv            # Dataset preparado para regressao (AQI)  
|       \-- dataset_classification.csv        # Dataset preparado para classificacao  
|-- notebooks/  
|   |-- 01_eda.ipynb                        # Analise exploratoria e diagnosticos  
|   |-- 02_preprocessing.ipynb              # Limpeza, tratamentos, OHE e escalas  
|   |-- 03_regression_analysis.ipynb         # Analise preditiva para Regressao (AQI)  
|   \-- 04_classification_analysis.ipynb     # Analise preditiva para Classificacao  
|-- src/  
|   |-- __init__.py                        # Inicializador do pacote modular  
|   |-- data_loader.py                    # Funcoes para carregamento de dados  
|   |-- eda.py                            # Funcoes analiticas e deteccao de outliers  
|   |-- preprocessing.py                  # Funcoes de higienizacao, codificacao e scaling  
|   \-- visualization.py                 # Funcoes padronizadas para geracao de graficos  
|-- reports/  
|   \-- figures/                          # Graficos de alta resolucao (300 DPI)  
\-- docs/  
    \-- relatorio_final.pdf                # Relatorio tecnico completo da atividade
```